


Woche 12

Freitag, 26. Mai 2023 11:21

Ausgleichsrechnung / Regression

Ziel: Finde Modellparameter, s.d. Daten möglichst gut vom Modell approximiert werden

Intuition:



Seien $y_i \in \mathbb{R}$ die gemessenen Werte für die Eingangsgrößen x_i .

Wir wollen das Modell f so bestimmen, dass $\sum_{i=1}^n |f(x_i) - y_i|^2 = \|f(x) - y\|_2^2$ minimal

Wieso $\|\cdot\|_2^2$? Wenn wir annehmen, dass unsere gemessenen y_i fast den tatsächlichen y_i^{exakt} entsprechen, d.h. bis auf einen Messfehler übereinstimmen ($y_i = y_i^{\text{exakt}} + \varepsilon_i$, $\varepsilon_i \sim N(0, \sigma^2)$), dann ist $f(x)$ die bestmögliche Approximation die wir erhalten können.

Formal: Sei $\vec{a} = (a_1, \dots, a_m)$ der Modellparametervektor und $f_{\vec{a}}: \mathbb{R} \rightarrow \mathbb{R}, x \mapsto y$

die von \vec{a} abhängige Modelfunktion. x_i : Messpunkte

y_i : Messwerte

Wichtig: Wir gehen davon aus, dass die x_i keinen Fehler haben

Falls $n > m \Rightarrow$ keine exakte Lösung, da nicht invertierbar

Bestimme nun \vec{a} , s.d. $\sum_{i=1}^n |y_i - f_{\vec{a}}(x_i)|^2$ minimal

Vektornotation:

$$F(\vec{a}) := \begin{pmatrix} y_1 - f_{\vec{a}}(x_1) \\ \vdots \\ y_n - f_{\vec{a}}(x_n) \end{pmatrix} \in \mathbb{R}^n \quad \|F(\vec{a})\|_2 \text{ minimal}$$

↑
Residuenvektor

Dann ist die optimale Wahl von \vec{a} gegeben durch $\hat{\vec{a}}^* = \underset{\vec{a} \in \mathbb{R}^n}{\operatorname{argmin}} \|F(\vec{a})\|_2$

Beispiel: Radikaktiver Zerfall

Menge N des noch nicht zerfallenen Material: $N(t) = N_0 e^{-\lambda t}$

N_0 : Anfangsmenge
 λ : Zerfallskonstante

Betrachten wir nun die Messzeiten t_i , $1 \leq i \leq n$ und die gemessenen,

fehlerbehafteten noch nicht zerfallen N_i . Dann wollen wir die Parameter $\vec{a} = (N_0, \lambda)$ finden, s.d.

$$F(N_0, \lambda) = \begin{pmatrix} N_1 - N_0(t_1) \\ \vdots \\ N_n - N_0(t_n) \end{pmatrix} \quad \text{und } \|F(N_0, \lambda)\|_2 \text{ minimal}$$

Lineare Ausgleichsrechnung:

$f_{\vec{a}}(x) = a_1 b_1(x) + \dots + a_m b_m(x)$ wobei $b_1, \dots, b_m: \mathbb{R} \rightarrow \mathbb{R}$ Basisfunktionen sind.

Intuitiv: $a_i \equiv$ linear effect of $b_i(x)$ on y which is not explained by the other b_j .
So können wir den Residuenvektor wie folgt schreiben:

$$F(\vec{a}) = \vec{b} - A \cdot \vec{a}$$


Dann: $\|F(\vec{a})\|_2$ minimal $\Leftrightarrow \|A\vec{a} - \vec{b}\|_2$ minimal

Wir suchen jetzt

$$A = \begin{pmatrix} b_1(x_1) & \dots & b_m(x_1) \\ \vdots & & \vdots \\ b_1(x_m) & \dots & b_m(x_m) \end{pmatrix}, \quad \vec{b} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

$$\vec{a}^* = \underset{x \in \mathbb{R}^m}{\operatorname{argmin}} \|Ax - b\|_2$$

Geometrisch:



Wie finden wir \vec{a}^* ?

a) QR	b) SVD	c) Normalengleichungen
⊖ nur für $m \gg n$ und vollen Rang	⊕ kein voller Rang ⊖ $m \gg n$	⊕ für dünn besetzte A ⊖ i.A. schlecht konditioniert

Python: $\vec{a} = \text{np.linalg.lstsq}(A, b)[0]$

$$\text{a) } \|Ax - b\|_2 = \|QRx - b\|_2 = \|Q^T(QRx - b)\|_2 = \|Rx - Q^Tb\|_2$$

$$Rx - Q^Tb = \begin{bmatrix} \hat{R} & 0 \\ 0 & * \end{bmatrix}x - \begin{bmatrix} \hat{Q}^T \\ * \end{bmatrix}b = \begin{bmatrix} \hat{R}x - \hat{Q}^Tb \\ * \end{bmatrix} \quad \text{nicht von } x \text{ abh.}$$

D.h. $\|Rx - Q^Tb\|_2$ minimal für $\hat{R}x - \hat{Q}^Tb = 0$

$$\Rightarrow \vec{a}^* = \hat{R}^{-1} \hat{Q}^T b$$

b) Analog zu QR: $\sum_{i=1}^r V_i^T x - U_i^T b = 0$

$$\Leftrightarrow \vec{a}^* = \underbrace{V_1 \sum_{i=1}^r U_i^T b}_{A^+}$$

A^+ Pseudoinverse

($A^+ \in \mathbb{R}^{n \times m}$ im Least square Sinn die beste Approximation an die Umkehrfunktion)

c) Normalengleichung

Wir wollen $f(\vec{x}) = \|Ax - b\|_2$ minimal

Idee: Minimum wenn $Df(\vec{x}) = 0$ und $D^2 f(\vec{x})$ pos. def.

Dann: $Df(\vec{x}) = 0 \Leftrightarrow A^* A \vec{x} = A^* b \quad (*)$

Falls A vollen Rang: $D^2 f(\vec{x})$ automatisch pos. definit

$$\vec{a}^* = \text{solve}(A^* A, A^* b)$$

\hookrightarrow i.A. $A^* A$ schlecht konditioniert aka. unbrauchbar