

Woche 10

Freitag, 12. Mai 2023 11:31

Linear - Implizite RK Verfahren

Idee: Nullstellen-Know-how auf RK-Verfahren anwenden?

Wieso? Wir wollen fsolve "überflüssig" machen

Autonomes AWP:

$$\begin{cases} \dot{y} = f(y) \\ y(t_0) = y_0 \end{cases}$$

diagonal-implizites RK - Verfahren

$$\frac{\begin{vmatrix} A & \\ & b^T \end{vmatrix}}{b^T} = \frac{\begin{vmatrix} a_{11} & \dots & 0 \\ \vdots & \ddots & a_{ss} \\ * & & \end{vmatrix}}{b_1 \dots b_s} \quad \text{wobei } a_{ii} \neq 0$$

Wir wissen, dass wir folgende Gleichungen lösen müssen:

$$k_i = f(y_0 + h \sum_{j=1}^{i-1} a_{ij} k_j)$$

$$\Leftrightarrow F_i(k) := k - f(y_0 + h \sum_{j=1}^{i-1} a_{ij} k_j + h a_{ii} k) = 0$$

$$\text{und } k_i = k^* \text{ s.d. } F(k^*) = 0$$

Idee: Anstatt das "teure" fsolve zu benutzen, machen wir NUR 1 Newton-Schritt

Problem: Verschlechtert Konvergenz

→ Lösung: Wähle Startwert k_i^0 für den Newtonschritt gut

$$\text{i.e. } k_i := k_i^0 = k_i^0 - Df(k_i^0)^{-1} F(k_i^0) \quad (*)$$

1-NS

Wir benötigen also $Df(k)$ (totale Ableitung)

$$Df(k) = 11 \cdot Df(y_0 + h \sum_{j=1}^{i-1} a_{ij} k_j + h a_{ii} k) \underset{\text{Kettenregel}}{=} h a_{ii}$$

Für den Startwert k_i^0 machen wir den Ansatz:

$$k_i^0 = \sum_{j=1}^{i-1} \frac{d_{ij}}{a_{ii}} k_j, \quad d_{ij} \in \mathbb{R}$$

d_{ij} bestimmen dabei das spezifische Verfahren \Rightarrow sind bekannt für gegebene Methode

Überlegung: d_{ij} versuchen gut zu wählen (für Konvergenz)

Aus ③ erhalten wir durch Multiplikation mit $DF(k_i^0)$:

$$\underbrace{DF(k_i^0)k_i}_A = \underbrace{DF(k_i^0)k_i^0 - F(k_i^0)}_B \quad (\text{S.204}) \quad \text{LGS}$$

in Python: $k_i = \text{solve}(A, b)$

Nützlich, da sie

- a) relativ schnell
- b) auf steife DGLs anwendbar

Matrix Zerlegungen

Ziel: Lindg-Wissen in Numerik übertragen und unterschiedliche Verfahren vergleichen

Problem: bei num. Rechnungen gibt es immer Rundungsfehler

⇒ möglichst stabile Verfahren, d.h. Verfahren bei denen das Resultat durch die Fehler nicht übermäßig beeinflusst wird

Was ist unser Mass für die "Stabilität":

Def: (rel. Kondition)

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ein math. Problem (z.B. lösen eines LGS mittels LU-Zerlegung). Sei x der analytische Input und \tilde{x} der fehlerbehaftete.

Dann ist die rel. Kondition (K_{rel}) definiert, s.d. $\exists S > 0$

$$\frac{\|f(\tilde{x}) - f(x)\|}{\|f(x)\|} \leq K_{\text{rel}} \frac{\|\tilde{x} - x\|}{\|x\|} \quad \forall \tilde{x} \in \mathbb{R}^n \text{ s.d. } \|\tilde{x} - x\| < S$$

Intuition: „Wie wird der Rundungsfehler im schlimmsten Fall vergrößert“

Im Fall für Matrizenzerlegungen / LGS:

$A \in GL_n(\mathbb{R})$: $K(A) = \|A\|_{\text{op}} \|A^{-1}\|_{\text{op}}$, wobei
 $\text{cond}(A)$

$$\|A\|_{\text{op}} := \sup_{\|x\|_2=1} \|Ax\|_2 = \sup_{\|x\|_2 \neq 0} \frac{\|Ax\|_2}{\|x\|_2}$$

≡ maximale Verzerrung der Einheitssphäre durch A



Wieso Sinnvol?

Betrachte das LGS $Ax = b$. Für eine rundungsfehler-behaftete rechte Seite

\tilde{b} finden wir die Näherungslösung \tilde{x} : $A\tilde{x} = \tilde{b}$

Wir definieren nun die Fehler $E_b = \|b - \tilde{b}\|_2$, $E_x = \|x - \tilde{x}\|_2$

Dann finden wir mit

$$\textcircled{*} \|b\|_2 = \|Ax\|_2 \leq \|A\|_{op} \|x\|_2$$

$$\textcircled{\Delta} E_x = \|x - \tilde{x}\|_2 = \|A^{-1}(b - \tilde{b})\|_2 \leq \|A^{-1}\|_{op} \|b - \tilde{b}\|_2$$

Eine Abschätzung für den rel. Fehler $\frac{E_b}{\|b\|_2} \stackrel{\textcircled{*}}{\Rightarrow} \frac{E_b}{\|A\|_2 \|x\|_2} \stackrel{\textcircled{\Delta}}{\geq} \frac{1}{\|A\| \|A^{-1}\|} \frac{E_x}{\|x\|_2}$

Damit gibt $\text{cond}(A)$ für LGS die schlimmst mögliche Fehlervergrößerung an

Dann:

$\text{cond}(A) \approx 1$: stabile Lösung von LGS
(kleine Rundungsfehler)

$\text{cond}(A) \gg 1$: Fehler von \tilde{x} kann gross werden (schlecht konditioniert)

Nächste Woche: Zerlegungen